

Estrategia para la detección de tipos de enfermedades oculares usando red neuronal SOM

Huarote Zegarra Raúl Eduardo¹, Vega Luján Yensi², Flores Masías Edward José³, Cesar Raul Cuba Aguilar³, Katherine Susan Llanos Chacaltana⁴, Larios Franco Alfredo Cesar¹, and Diaz Reategui Monica⁵

¹Universidad Nacional Tecnológica de Lima Sur, Perú, rhuarote@untels.edu.pe, alarios@untels.edu.pe

²Universidad Nacional de Trujillo, Perú, yensi.vega@gmail.com

³Universidad Nacional Federico Villarreal, Perú, eflores@unfv.edu.pe, ccubaa@unfv.edu.pe

⁴Universidad Privada del Norte, Perú, susan.llanos@upn.edu.pe

⁵Universidad Privada Norbert Wiener, Perú, monica.diaz@uwiener.edu.pe

Abstract– *This research aims to cover a need to be able to classify according to the funds of eyes in diabetic retinopathy disease, how to convert to gray tone, perform an equalization, apply the canny edge highlighting algorithm and apply morphological operations so that a SOM (self-organization map) neural network can be entered and classified. To achieve this, it is classified as 0 to diabetic retinopathy, 1 to glaucoma and 3 to healthy eyes. To corroborate this strategy, a public database of Fundus-images has been taken, being 45 images of eyes for training and for tests 15 images that were not part of the training were used and for the tests 3 images that were not part of the training were used and each grayscale image is scaled to a dimension of 256x256 pixels, managing to demonstrate with this strategy an affectivity of 93.7% certainty in the identification of class of eye disease.*

Keywords– *Strategy, SOM neural network, eyes, glaucoma, diabetic retinopathy.*

Resumen– *La presente investigación pretende cubrir una necesidad de poder clasificar de acuerdo a los fondos de ojos en la enfermedad retinopatía diabética, glaucoma o que sean identificados como ojos sanos. Para lograr esto la estrategia particular está en cómo preparar las imágenes digitales en una secuencia, como convertir a tono de gris, realizar una ecualización, aplicar el algoritmo de resalte de borde canny y aplicar operaciones morfológicas para que se pueda ingresar a una red neuronal SOM (mapa autoorganizativo) y poder ser clasificada. Para lograr esto se tiene clasificada como 0 a retinopatía diabética, 1 a glaucoma y 3 a los ojos sanos. Para corroborar esta estrategia se ha tomado una base de datos pública de Fundus-images, siendo 45 imágenes de ojos para el entrenamiento y para las pruebas se usaron 15 imágenes que no eran parte del entrenamiento y cada imagen en escala de grises está escalada a una dimensión de 256x256 píxeles, logrando demostrar con esta estrategia una afectividad de 93.7% certeza en la identificación de clase de enfermedad ocular.*

Palabras clave – *Estrategia, Red neuronal SOM, ojos, glaucoma, retinopatía diabética.*

I. INTRODUCTION

Las enfermedades glaucoma y retinopatía diabética son clasificados según [1] como 9B71.0 y 9C61 respectivamente. Desde que OPS [2] considera que la consecuencia del daño de los pequeños vasos sanguíneos de la retina que se va

acumulando a lo largo del tiempo y esto genera la retinopatía diabética, por lo que es una causa importante de ceguera. Para tener en cuenta el nivel de gravedad, el 2,6% de los casos mundiales de ceguera es consecuencia de la diabetes, lo que indica que la diabetes es una de las consecuencias comunes la ceguera. Así también [3] considera que la retinopatía diabética es una importante causa de la ceguera y se evidencia en el daño de los capilares de la retina que viene de la acumulación de a lo largo del tiempo, considerando que 1 millón de personas lo ha padecido y por ende se han quedado ciegos. Así también [4] hace referencia por lo menos 2200 millones de personas tienen problema visual como el glaucoma, y que el 45.4% pudieron haberse evitado con un tratamiento adecuado. Para [5] considera que la presencia del glaucoma daña el nervio óptico del ojo, esto se produce cuando en el área ocular se acumula fluido en la parte delantera del ojo, por tanto el exceso de este fluido hace que aumente la presión en esta zona (el ojo) y por consecuencia daña el nervio óptico. [6] hace referencia a la duración de la diabetes en la presencia del ojo y la falta de tratamiento, y la falta de control de los niveles elevados de hemoglobina A1c y si a esto se le añade la hipertensión arterial, se considera como riesgo importantes para la ceguera por la influencia de la retinopatía diabética. Así en los datos y cifras presentados por [7] indica que el deterioro de la visión y por consecuencia la ceguera se da en las personas con 50 años corroborado por [8], aunque esta enfermedad se puede dar en cualquier edad, generando un gasto a nivel mundial de US\$ 244 000 millones por miopía y US\$ 25 400 millones por presbicia no corregidas y que principalmente se da en zonas rurales y marginales. Así también en el libro de [9] hace referencia a los factores de riesgo y la clasificación de la retinopatía diabética a partir de diversos casos clínicos para abordar diversos tratamientos en situaciones complicadas, ayudando a seleccionar de la mejor manera el fármaco más adecuado para lograr mejores resultados respecto al paciente. En las situaciones de los infantes [10] también se contempla los últimos avances en el campo de la genética ocular, opciones de tratamientos para casos de hemangioma capilar y el queratocono, también

contempla aplicaciones como la terapia genética, así también incluye imágenes.

Por tanto es necesario tomar en cuenta estos sucesos, en ese contexto es necesario hacer diferentes análisis y aplicar diferentes estrategias para identificar estas enfermedades y poder ser aplicados en un medio tecnológico más accesible y de modo masivo.

En este campo se han realizado múltiples y relevantes investigaciones enmarcadas en este escenario, tales como [11] donde valida una puntuación de gravedad vascular como un resultado idóneo para las aplicaciones en diferentes softwares basados en inteligencia artificial, para la retinopatía en personas prematuras, logrando a través de la comparación con las etiquetas de gravedad de la enfermedad ordinal para el estadio los valores de tasa de 0.67 y 0.88 para Kappa y CC respectivamente. También en la investigación de [12] a partir de la recopilación de un conjunto de las imágenes realiza el entrenamiento basado en redes neuronales artificiales para encontrar retinopatía en estadio prematuro (ROP), usando 5842 imágenes de fondo de retina recolectados en 963 personas en edad prematura, obteniendo un resultado de 92.2% de certeza con la comparación de 8 especialistas internacionales. Así también [13] menciona que el alto grado de azúcar en la sangre es probable que desarrolle retinopatía diabética (RD) para ello usando visión computacional usa el canal rojo para tomar como patrones de entrada para la red neuronal, una estrategia que aporta en la clasificación de retinopatía. En la investigación de [14] considera que las aplicaciones basadas en inteligencia artificial aplicada en el diagnóstico de glaucoma, tiene un gran potencial, ya que aumentar ampliamente el acceso a la información y esta publicada para todo el mundo, y se pueden dar resultados de una evaluación de nivel experto o especialista, y pueden tener acceso a las regiones más remotas. Otra investigación aplicado al glaucoma en la ponencia de [15] llamada “Inteligencia artificial para el glaucoma”, donde presentó las aplicaciones de la IA para los diagnósticos en este campo, a partir de las fotografías del fondo de ojo, imágenes de tomografía del ojo, evaluación en base al estándar perimetral y gonioscopí. Así también [16] en su investigación aplica modelos de decisión y las implicaciones de la aplicación de los métodos basados en OCT (tomografía de coherencia óptica), donde usa la técnica del aprendizaje automático para el diagnóstico y tratamiento de diversas afecciones oftalmológicas. También [17] usa como herramienta el árbol de decisión para evaluar en función de los síntomas depresivos y de ansiedad a 48 niños menores de 18 años con glaucoma con una precisión de 87.5%. En [18] propone un nuevo modelo de red DAG para la clasificación de la retinopatía diabética basado en fusión múltiple a partir de las funciones de imagen de fondo del ojo, logrando alcanzar un nivel de certeza de 98.7% a partir de una base de datos y 98.5% para datos en campo. En la investigación de [19] usó la red neuronal convolucional Multi-Branch aplicada a la retinopatía diabética, logrando con este modelo una precisión

de clasificación de 96.11%, una sensibilidad de 98.08%, una especificidad de 89.43% en la detección de la retinopatía diabética, en pruebas de campo logró un 90.56% de certeza. También [20] en su investigación aplica la características semánticas basadas en RNN para la clasificación, logrando una precisión de 97.22% en detección de la retinopatía diabética.

Por tanto la presente investigación lo que pretende es identificar la enfermedad de glaucoma y retinopatía diabética en base a la red neuronal artificial, para tener un criterio más cercano a en el diagnóstico usando la red neuronal backpropagation.

II. ESTRATEGIA

Existe diferentes puntos de vista respecto a las estrategias, en esta investigación se va a considerar a las vinculadas con las redes neuronales artificiales, como [21] usa una estrategia previa para convertirlo a patrones de entrada a las redes neuronales artificiales, que consta de una serie de pasos que restringe los contactos neuronales durante el cableado cerebral siendo procesos dinámicos en tiempo y espacio. Otra estrategia aplicada en este sector es de [22] donde clasifica los tipos de células, basándose en el análisis de la vinculación morfológica de la proyección axonal, ya que cambian en función del tiempo, buscando una medida adecuada, ya que son diversos. También [23] aplica estrategia sensoriomotora a las neuronas, para la discriminación de formas usando modelo lineal generalizado. La estrategia aplicada de [24] para la detección de Covid-19 en imágenes de torax, fue aplicando una eliminación de ruido previa al ingreso de la red, mejorando la sensibilidad y especificidad. Otra estrategia aplicada por [25] consiste en aplicar previamente al ingreso de datos a la red neuronal artificial, a cada imagen de muestra granular extrae información del PSD y morfología, a partir de ello se aplica la red neuronal BiLSTM. En el ámbito de la energía [26] aplica una estrategia basado en CEEMDAN para posteriormente aplicar a las redes neuronales artificiales, para poder pronosticar la radiación solar con mayor precisión. También en la investigación de [27] aplica la estrategia a las imágenes, que es una combinación de contornos CT y GTV, para tener el insumo para la red neuronal artificial y así poder predecir los diferentes resultados clínicos en los datos de cáncer de H&N.

Tal como se muestra en la Fig 1. Realiza un gráfico genérico de este punto acerca de la estrategia previa para la aplicación de redes neuronales artificiales a las imágenes de los ojos.




Fig. 1 Estrategia previa a la aplicación de la IA.

En la Fig 2, se evidencia de que cada uno de los casos de enfermedades a querer agrupar se encuentra en formato tiff y tienen una dimensión de 3504x2336 pixeles, esto antes de aplicar la estrategia, ya que después de aplicar la estrategia se obtiene su representativo en dimensión 18x18 de cada imagen. Si este último se le estira a se obtendrá un arreglo de 1x784, con valores de [0 a 255], pero este arreglo contiene valores enteros, lo que implica de manera necesaria pasarlo a reales en un rango de [0.0 a 1.0], para ello se usaría el método de escalación, tal como se muestra en la tabla I, cabe resaltar que el proceso inverso es de regresar al tono de gris en un valor de tipo pixel.




Fig. 2 Estrategia previa para el entrenamiento de la red SOM.

TABLA I

TABLA DE ECUACIONES PARA REALIZAR EL ESCALADO Y EL PROCESO INVERSO

Ecuación	Detalle	Observación
$r = \frac{Y - \text{Min}}{\text{Max} - \text{Min}}$	r: valor escalado Y: valor a escalar, Min: Valor mínimo del pixel ósea 0 Max: máximo del pixel ósea 255.	Necesario para escalar en el rango de 0.0 a 1.0
$Y = r(\text{Max} - \text{Min}) + \text{Min}$		Necesario para regresar la proporción original en función de r

<https://www5.cs.fau.de/> es un conjunto de datos de imágenes de ojos que tienen la particularidad de padecer glaucoma, retinopatía diabética y también de ojos sanos, que consta de un conjunto de 45 ejemplares de cada uno, así como para el testeo se tiene un conjunto de prueba de 3 imágenes ejemplares. Cada ejemplar es una imagen en escala de grises de 3504x2336, asociada con una etiqueta de H, G y DR haciendo referencia a casos de H: sano, G: glaucoma y DR: Retinopatía diabética. Por tanto son 3 clases las que se van a considerar para la presente investigación. Las imágenes de esta fuente de datos de ojos en los diferentes estados de salud, sirven para poder comprobar la investigación de poder agruparlas en las 3 clases establecidas y para la evaluación comparativa de los algoritmos de aprendizaje automático basado en red SOM. Teniendo en cuenta que para la evaluación o mapeo se debe realizar el mismo procedimiento a las imágenes para el entrenamiento (ósea hacer su representativo), por lo tanto deben tener el mismo tamaño de imagen y estructura de divisiones de entrenamiento y prueba. Por tanto proporciona el insumo necesario para poder aplicar en esta investigación. Etiquetas

Cada ejemplar de entrenamiento y prueba se asigna a una de las siguientes etiquetas:

- 0 H Sano
- 1 G Glaucoma
- 2 DR Retinopatía diabética

III. INTELIGENCIA ARTIFICIAL

Para [28] la inteligencia artificial lo define como “el medio por el cual las computadoras, los robots y otros dispositivos realizan tareas que normalmente requieren de inteligencia humana”, así también [29] considera a la IA que “es el estudio de cómo lograr que las computadoras realicen tareas que, por el momento, los humanos hacen mejor”, también [30] afirma que para la IA “es la rama de la ciencia de la computación que se ocupa de la automatización de la conducta inteligente”, así también [31] asevera que “el medio por el cual las computadoras, los robots y otros dispositivos realizan tareas que normalmente requieren de la inteligencia humana”. También [32] afirma que la inteligencia artificial puede definirse como “si bien es imposible pronosticar con

precisión lo que se puede esperar de esta disciplina en el futuro, es evidente que las computadoras que posean una inteligencia a nivel humano o superior, tendrán repercusiones importantes en la vida diaria, así como en el devenir de la civilización”. Otro punto de vista [33] considera que la IA “está formada por una serie de algoritmos lógicos suficientemente entrenados a partir de los cuales las máquinas son capaces de tomar decisiones para casos concretos a partir de normas generales”, aseverando que va a ser parte de nuestra cotidianidad, ya que ello nos facilita las labores en diferentes aspectos y toma cierto grado de autonomía por nosotros. También para [34] considera a la inteligencia artificial como “la construcción de algoritmos ha logrado que las computadoras y las máquinas aprendan a resolver problemas” en los diferentes campos como la medicina, entre otros campos.

Por tanto la inteligencia artificial emula en lo posible todas las capacidades propias del humano plasmadas en algoritmos, agenciándose de tecnologías de información (software y hardware) para su implementación.

A. Red neuronal artificial

Para [35] las redes neuronales artificiales “están formadas por capas de variables interconectadas entre sí con unos pesos que el algoritmo va calculando y ajustando mediante iteraciones (repeticiones) de un proceso que se conoce como «descenso del gradiente»”. Para [36] atribuye el éxito de las redes neuronales artificiales en usar varios algoritmos de optimización y varias estructuras de la red, como la normalización por lotes.

Por tanto la red neuronal artificial emula en algoritmos la manera de aprender basándose del modelo biológico del humano, a pesar que existen otros factores o niveles que aún no están contempladas.

B. Red neuronal SOM

A partir de la publicación de [37] ha mostrado el modelo de red neuronal autoorganizativo, y se basó para su investigación en la manera como la información es captada a través de los órganos sensoriales de los animales (específicamente en el córtex superior), donde las zonas detectoras se ordenan y representan internamente formas de mapas bidimensionales, en este mapa las neuronas compiten y se agrupan según las características ingresadas. Este tipo de red neuronal permite clasificar de acuerdo a los patrones característicos, este tipo de red neuronal tiene un aprendizaje basado en competencia, por tanto no se considera un tutor para que maneje el error en el proceso de aprendizaje, ya que no se considera un valor deseado en el cual tienda los resultados. Formalizado en la ecuación 1 para encontrar la neurona vencedora ya se realiza por un método competitivo, la ecuación 2 refleja la actualización de pesos y la ecuación 3 para encontrar el radio. En la Fig. 3 un ejemplo de agrupación de datos mediante colores. Este modelo de clasificación por

medio de la red SOM se puede aplicar en la clasificación enfermedades oculares a partir de las imágenes que son obtenidas de una base de datos públicos, considerando los parámetros de entrada para poder utilizar la red neuronal.

$$\min \|X_p - W_j\| = \min \sum_{i=1}^N (X_{pi} - W_{ji})^2 \quad (1)$$

Dónde: $X_p: X_{p1}, X_{p2}, \dots, X_{pN}$, y el vector de pesos W_j :

$$W_{j1}, W_{j2}, \dots, W_{jN}$$

$$\Delta W_{ji}(n+1) = \alpha(n)(X_{pi} - W_{ji}(n)) \quad (2)$$

Donde n: es el número de ciclos, α es la tasa de aprendizaje

$$r(t) = r_0 e^{-\frac{t}{\lambda}} \quad (3)$$

Dónde: r_0 es el radio inicial para cubrir todos los nodos.




Fig. 3 Creación de figura en ejemplo del mapa autoorganizado de kohonen.

En la Fig. 4 muestra la arquitectura competitiva de la red neuronal SOM, en la capa de entrada que tiene N neuronas de manera lineal donde representan la información inicial y a su vez estos se transmiten los datos a la capa competitiva, formada por M neuronas para realizar el proceso de aprendizaje. En cada neurona i está conectada con cada una de las neuronas de la capa de competitiva j mediante un W_{ji} que tiene asociado, considerando que una neurona elegida pertenece a una vecindad N_j de la neurona j, y la cantidad de sus vecinas es fijo durante el proceso de entrenamiento, por tanto la elegida es resaltada y los que están a su costado tienen cierto grado de afectación en función de la distancia del elegido, donde por lo general se establece con una matriz llamada gaussiana.




Fig. 4 Representación de la clasificación de tipo de enfermedad ocular usando la red SOM.

IV. PROCESO DE APRENDIZAJE

En el proceso de aprendizaje de la red neuronal SOM al aplicar la estrategia establecida, genera un gráfico de índices, propio de la red SOM, donde se ve agrupada por las 3 clases a las 45 imágenes oculares, tal como se muestra en la Fig 5. Estas clases se pueden representar de esta manera según las etiquetas de la tabla II:

TABLA II
CLASE, ETIQUETA Y DETALLE DE LAS ENFERMEDADES OCULARES

Clase	Etiqueta	Detalle
0	H	En la imagen identificado como ojo Sano
1	G	En la imagen identificado con la enfermedad Glaucoma
2	DR	En la imagen identificado con la enfermedad Retinopatía diabética




Fig. 5 Imágenes oculares etiquetadas, (a) retinopatía diabética, (b) glaucoma y (c) ojo sano.

La previa de pasos para aplicar, como resultado obtenemos en la siguiente figura, necesario para que pueda ingresar a la red neuronal artificial SOM, considerando que estos dato (finales) es necesario estirarlo para que ingrese como patrones de entrada, tal como se visualiza en la Fig 6.




Fig. 6 Una imágenes oculares aplicando la estrategia, (a) tono de gris, (b) canny y (c) binarizada inversa.

En la Fig 7 y su representación de etiquetas en la Fig 8 se visualiza la matriz index agrupada después del aprendizaje no supervisado, donde la parte circular rojo representa a la clase de los ojos sanos, la parte triangular verde representa a la clase de los ojos con glaucoma y la parte triangular azul representa a la clase de los ojos con Retinopatía diabética. A partir de los datos entrenados, representado en la matriz index, se ha realizado las pruebas, donde a las pruebas de las mismas imágenes de entrenamiento (45 imágenes) se ha obtenido un 100% de certeza, frente a las imágenes que no han sido parte del entrenamiento (15 imágenes), obtuvo un resultado de 93.7% en promedio, tal como se muestra en la Tabla III, y una de las pruebas se evidencia en la Fig 9.

TABLA III
DETALLE DEL PORCENTAJE DE CERTAZA EN MAPEO SEGUN LAS CLASE DE ENFERMEDADES OCULARES

Clase	Etiqueta	% de certeza con imágenes de entrenamiento (45)	% de certeza con imágenes que no son parte del entrenamiento (15)
0	H	100 %	93 %
1	G	100 %	94 %
2	DR	100 %	94 %

En la Fig 7 se visualiza que en base a la variable de la cantidad de neuronas y ver la variación según la cuantización del error, se observa que van desde 10 hasta el valor 40 como límite para el valor las cantidades de neuronas, según los resultados reflejados en la gráfica, con valores 10 el aprendizaje toma un

tuna cuantización del error más visible de 24.5%, mientras más neurona utilizamos, hasta llegar a un valor ideal para las neuronas 15, generando una cuantización de error de 18,11%, y esto se logra establecer la cuantización de error a pesar de incrementar la cantidad de neuronas.




Fig. 7 Matriz index de la red SOM aplicada a las 45 imágenes y 3 clases




Fig. 8 Matriz index de la red SOM con las etiquetas de las 3 clases



Fig. 9 ejemplo en google colab de una de las pruebas.

La cantidad de iteraciones es relevante, por que hace que genere un agrupamiento ideal, cabe resaltar que esto puede llevar en desventaja si es que se exagera, ya que consume recurso, para la presente investigación se consideró los parámetros para la red neuronal SOM lo siguiente:

Máximas iteraciones a 100, alpha máximo a 0.5, dimensión de la matriz competitiva de 10x10, dimensión de la matriz index 10x10, cantidad de patrones de entrada a 324, topología hexagonal, función de activación la distancia euclidean. Con los datos mencionados anteriormente si se va incrementando la cantidad de iteraciones, va reduciendo el error, como se observa en la Fig. 10 donde se muestra la cuantización de errores frente a las cantidades de iteraciones.




Fig. 10 Cuantización de error frente a las cantidad de iteraciones

V. CONCLUSIONES

Al aplicar la estrategia propuesta para esta investigación y aplicar la red SOM, se obtuvo como resultado de efectividad de 93.7% en la clasificación de enfermedades oculares (glaucoma, retinopatía diabética o si es que es ojo sano), para lograr ello se usó 45 imágenes de la base de datos pública de Fundus-images para el entrenamiento de la red, representando un valor alentador, considerando que las pruebas para el testeo se ha realizado las 15 imágenes clasificadas en cada una de las clases establecidas y que no fueron parte del entrenamiento.

Cada vez que la matriz index genere los datos de las clases, se agruparán las clases de manera diferente, los valores de las etiquetas que representa cada caso (H, G, DR) estarán en posiciones diferentes. En la Fig 8, se muestra la gráfica del resultado de la aplicación del modelo de la red SOM propuesto por [37] y la aplicación de la estrategia en la Fig 2. Al aplicar la red neuronal SOM para clasificar tipos de enfermedades oculares como la retinopatía diabética y glaucoma aporta a nuevas investigaciones, ya que se puede

extender a otras enfermedades. Se ha utilizado la librería Minisom en un entorno Colab, donde nos proporcionan datos suficientes para realizar un buen análisis de nuestros resultados y obtener más información. Tal como se muestra en la siguiente Fig 11.




Fig. 11 Parte del código Fuente para realizar el aprendizaje.

VI. DISCUSIÓN

Si hacemos la comparativa de los resultados obtenido por [17] indica que usando árbol de decisión tiene una precisión de 87.5% frente a la presente investigación usando una estrategia de datos y la red neuronal SOM tiene 93.7%. Teniendo en cuenta que los casos usan imágenes que tienen retinopatía diabética, tal como la investigación de [19] que tuvo un 96.11% de certeza implicando una diferencia mayor de 2.41% de precisión frente a la presente investigación, por tanto se requiere unos ajustes para alcanzar o superar esta precisión.

AGRADECIMIENTO

Agradecimiento a todos los participantes de la presente investigación, con el fin de cubrir una necesidad de clasificar los diagnósticos de enfermedades oculares usando redes neuronales artificiales, para la clasificación de glaucoma, retinopatía diabética y ojo sano basado en inteligencia artificial, específicamente en la red neuronal artificial SOM y poder tomar mejores decisiones al momento de agrupar.

REFERENCES

- [1] Clasificación Internacional de Enfermedades, “The global standard for diagnostic health information”, 2022. [Online]. Available: <https://icd.who.int/en> [Accessed: Mar. 01, 2022].
- [2] Organización Panamericana de la Salud, “Diabetes”, 2022. [Online]. Available: <https://www3.paho.org> [Accessed: Mar. 01, 2022].
- [3] Organización Mundial de la Salud, “Diabetes”, 2022. [Online]. Available: <https://www.who.int/es/news-room/fact-sheets/detail/diabetes> [Accessed: Mar. 01, 2022].
- [4] Organización Mundial de la Salud, “La OMS presenta el primer Informe mundial sobre la visión”, 2019. [Online]. Available: <https://www.who.int/es/news-room/08-10-2019-who-launches-first-world-report-on-vision> [Accessed: Mar. 01, 2022].
- [5] American Academy of Ophthalmology, “¿Qué es la retinopatía diabética?”, 2021. [Online]. Available: <https://www.aao.org/salud-ocular/enfermedades/retinopatia-diabetica> [Accessed: Mar. 01, 2022].
- [6] Organización mundial de la Salud, “Informe mundial sobre la visión”, 2020, pp 9.

- [7] Organización Mundial de la Salud, “Ceguera y discapacidad visual”, 2021. [Online]. Available: <https://www.who.int/es/news-room/fact-sheets/detail/blindness-and-visual-impairment> [Accessed: Mar. 01, 2022].
- [8] Organización Panamericana de la Salud, “Salud visual”, 2021. [Online]. Available: <https://www.who.int/es/news-room/fact-sheets/detail/blindness-and-visual-impairment> [Accessed: Mar. 01, 2022].
- [9] Caroline R. Bauman, Jay Duker, “Manejo de la retinopatía diabética”, 2018, Elsevier, eBook ISBN: 9788491134237
- [10] Kenneth Wright, Yi Ning Strube, “Oftalmología pediátrica para atención primaria”, 2021, Elsevier.
- [11] J. Campbell, M. Chiang, J. Chen, D. Moshfeghi, E. Nudleman, P. Ruambivongsuk, H. Cherwek, C. Cheung, P. Singh, J. Kalpathy-Cramer, S. Ostmo, M. Eydelman, P. Chan, A. Capone and Comité Ejecutivo de CCOI y el Grupo de Trabajo de Retinopatía del Prematuro de CCOI, “Artificial Intelligence for Retinopathy of Prematurity: Validation of a Vascular Severity Scale against International Expert Diagnosis”, Ophthalmology, 2022.
- [12] A. Coyner, J. Chen, K. Chang, S. Ostmo, P. Chan, M. Chiang, J. Kalpathy-Cramer, P. Campbell and Imaging and Informatics in Retinopathy of Prematurity Consortium, “Synthetic Medical Images for Robust, Privacy-Preserving Training of AI: Application to Retinopathy of Prematurity Diagnosis”, Ophthalmology Science, 2022.
- [13] Padmanayanaa and B. Anoop, “Binary Classification of DR-Diabetic Retinopathy using CNN with Fundus Colour Images”, materialstoday, 2022.
- [14] J. Schuman, M. Ramos Cadena, R. Gee, L. Al-Aswad and F. Medeiros, “A Case for the Use of Artificial Intelligence in Glaucoma Assessment”, 2021.
- [15] L. Al-Aswad, R. Ramachandran, J. Schuman, F. Medeiros, M. Eydelman and Collaborative Community for Ophthalmic Imaging Executive Committee and Glaucoma Workgroup, “Artificial Intelligence for Glaucoma: Creating and Implementing AI for Disease Detection and Progression”, 2022.
- [16] D. Hood, S. La Bruna, E. Tsamis, K. Thakoor, A. Rai, A. Leshno, C. de Moraes, G. Cioffi and J. Liebmann, “Detecting glaucoma with only OCT: Implications for the clinic, research, screening, and AI development”, Progress in Retinal and Eye Research, 2022.
- [17] S. Wy, S. Choe, Y. Jeong Lee, E. Bak, M. Jang, S. Chan Lee, A. Ha, J. Wook Jeoung, K. Ho Park and Y. Kook Kim, “Decision Tree Algorithm-Based Prediction of Vulnerability to Depressive and Anxiety Symptoms in Caregivers of Children with Glaucoma”, American Journal of Ophthalmology, 2022.
- [18] Lingling Fang, Huan Qiao, “Diabetic retinopathy classification using a novel DAG network based on multi-feature of fundus images”, 2022, Biomedical Signal Processing and Control.
- [19] B. Dong, X. Wang, X. Qiang, F. Du, L. Gao, Q. Wu, G. Cao, C. Dai, “A Multi-Branch Convolutional Neural Network for Screening and Staging of Diabetic Retinopathy Based on Wide-Field Optical Coherence Tomography Angiography”, 2022, IRBM.
- [20] G. Sivapriya, V. Praveen, P. Gowri, S. Saranya, S. Sweetha, Kukunoor Shekar, “Segmentation of Hard exudates for the detection of Diabetic Retinopathy with RNN based semantic features using fundus images”, 2022, Materials Today proceedings.
- [21] E. Agil, A. Kulkarni and P. Robin Hiesinger, “Neuronal strategies for meeting the right partner during brain wiring”, Current Opinion in Neurobiology, Volume 63, August 2020, Pages 1-8.
- [22] J. Winnubst, N. Spruston and J. A. Harris, “Linking axon morphology to gene expression: a strategy for neuronal cell-type classification”, Current Opinion in Neurobiology, Volume 65, December 2020, Pages 70-76.
- [23] C. Rodgers, R. Nogueira, B. Pil, E. Greeman, J. Park, Y. Hong, S. Fusi and R. Bruno, “Sensorimotor strategies and neuronal representations for shape discrimination”, Neuron, Volume 109, Issue 14, 21 July 2021, Pages 2308-2325.e10.
- [24] M. Momeny, A. Neshat, M. Hussain, S. Kia, M. Marhamati, A. Jahanbakhshi and G. Hamarneh, “Learning-to-augment strategy using

Digital Object Identifier: (only for full papers, inserted by LACCEI).
ISSN, ISBN: (to be inserted by LACCEI).
DO NOT REMOVE

- noisy and denoised data: Improving generalizability of deep CNN for the detection of COVID-19 in X-ray images”, *Computers in Biology and Medicine*, Volume 136, September 2021,
- [25] P. Zhang and Y. Zhen-Yu, “A novel deep learning-based modelling strategy from image of particles to mechanical properties for granular materials with CNN and BiLSTM”, *Computer Methods in Applied Mechanics and Engineering*, Volume 382, 15 August 2021.
 - [26] B. Gao, X. Huang, J. Shia, Y. Taia and J. Zhang, “Hourly forecasting of solar irradiance based on CEEMDAN and multi-strategy CNN-LSTM neural networks”, *Renewable Energy*, Volume 162, December 2020, Pages 1665-1683.
 - [27] S. Pang, M. Field, J. Dowling, S. Vinod, L. Holloway and A. Sowmy, “Training radiomics-based CNNs for clinical outcome prediction: Challenges, strategies and findings”, *Artificial Intelligence in Medicine*, Volume 123, January 2022.
 - [28] Gómez, R., *La inteligencia Artificial ¿Hacia dónde nos lleva? ¿Cómo lo vez?*, México, UNAM, 2013.
 - [29] Elaine Rich y Knight Kevin. *Inteligencia Artificial*. Segunda Edición. McGraw Hill: México, 1994
 - [30] Luger, G., Stubblefield W., *Artificial Intelligence: Structures and Strategies for Complex Problem Solving*, BC, 1993
 - [31] G. H. Renato, “La inteligencia artificial. ¿Hacia dónde nos lleva? ¿Cómo ves?” México: UNAM, 2013
 - [32] P. P. Cruz, “Inteligencia artificial con aplicaciones a la ingeniería”, México: Alfaomega Grupo Editores S.A. de C.V., México, 2010
 - [33] J. Avila-Tomás, M. Mayer-Pujadas, V. Quesada-Varela, “Artificial intelligence and its applications in medicine I: introductory background to AI and robotics”, *Atención Primaria*, Volume 52, Issue 10, December 2020, Pages 778-784.
 - [34] M. Regalado, A. Medina and C. Pizarro, “Artificial intelligence: phones smart phones and advanced technology stethoscopes”, *Atención Primaria*, Volume 53, Issue 10, December 2021.
 - [35] A. Martorell, A. Martín-Gorgojo, E. Ríos-Viñuela, J. M. Rueda-Carnero, F. Alfageme and R. Taberner, “Artificial Intelligence in Dermatology: A Threat or an Opportunity?”, *Actas Dermo-Sifiliográficas*, Volume 113, Issue 1, January 2022, Pages 30-46.
 - [36] H. Zhang, L. Feng, X. Zhang, Y. Yang and J. Li, “Necessary conditions for convergence of CNNs and initialization of convolution kernels”, *Digital Signal Processing*, Volume 123, 30 April 2022.
 - [37] K. Teuvo, “Self-organizing maps”, Berlin: Springer, 1989.